CASE TÉCNICO · ENGENHARIA DE DADOS

Pipeline de Dados SIGMU

Do dado público à visão analítica

Arquitetura · Qualidade · Modelagem · Resultados

Eliana Rodrigues

Problema de negócio

Objetivo: identificar quais regionais e assuntos concentram maior volume de solicitações, maior tempo de atendimento e maior valor executado.

- Transformar arquivos CSV em dados estruturados e consultáveis.
- Relacionar solicitações, serviços e itens executados.
- Garantir que os relacionamentos não distorçam os indicadores.
- Produzir uma camada analítica que responda às consultas solicitadas.

Fontes de dados

Arquivos públicos do SIGMU (C3SL/UFPR) · recorte **21/09/2016**

Tabela	Papel no pipeline
SERVICO_SOLICITADO	Solicitações e atributos
SITUACAO_SOLICITACAO	Histórico de situações
SERVICO	Serviços dos pedidos
SERVICO_EXECUTADO	Execução e itens
Bairro / tipo	Dimensões opcionais

CSV ; · Latin-1 · encoding, nulos e linhas malformadas

Arquitetura



Componentes:

- Python — orquestração
- Docker Compose — serviços
- SeaweedFS — bucket `lake`
- Parquet e SQL — transformação

Bronze: ingestão e rastreabilidade

- Download das fontes públicas.
- Preservação dos bytes e do nome original.
- Manifesto: URL, período, extração, tamanho, SHA-256.
- Núcleo obrigatório; dimensões opcionais.
- Reexecução no mesmo snapshot substitui objetos.

Silver: padronização e qualidade

- Tipos adequados; vazios → nulos.
- Linha de máscara removida.
- Quarentena se quantidade de campos ≠ header.
- Métricas de descarte e datas inválidas.
- Deduplicação por chave natural.

Resultado: 3 linhas em quarentena (2 solicitação, 1 serviço).

Relacionamentos e modelagem

SERVICO_SOLICITADO — uma linha por solicitação

↓

SERVICO — um pedido pode ter vários serviços

↓

SERVICO_EXECUTADO — um serviço pode ter vários itens

Agregação antes dos joins para preservar o grão do fato.

Decisão central: Gold com **uma linha por SSO_IDF**.

Gold: regras de negócio

- Volume: solicitações distintas.
- Tipo: `SSO_ASSUNTO` em maiúsculas.
- Regional em maiúsculas; vazio → NÃO INFORMADO.
- `possui_execucao` para ausência de serviço.
- Tempo com fallback documentado.
- Tempo negativo: fora da média/mediana, mas contabilizado.
- Quantidade e valor agregados; ausência permanece nula.