Pipeline SIGMU

Arquitetura medalhão para a manutenção urbana de Curitiba

Recorte de 21/09/2016 · defesa técnica · cerca de 20 minutos

Roteiro

Bloco	Tempo
Problema e o que a pergunta exige do modelo	4 min
Fontes e qualidade na origem	4 min
Arquitetura medalhão, Bronze, Silver e Gold	7 min
Resultados do recorte	3 min
Reprocessamento, limites e evolução	2 min

A pergunta

Dados públicos de solicitação de manutenção urbana.

Quais tipos de serviço e quais regiões concentram maior volume, maior tempo de atendimento e maior valor executado?

Volume	Tempo	Valor
conta solicitação, uma vez	abertura até a primeira execução	soma dos itens executados

O que a pergunta exige

- **Grão do fato:** 1 linha por solicitação (`SSO_IDF`)
- **Tipo:** assunto do pedido (`SSO_ASSUNTO`)
- **Região:** regional (`SSO_REGIONAL`)
- **Vários serviços:** somar valor e quantidade; guardar a primeira e a última execução
- **Sem execução:** a solicitação continua no fato

Por que assunto, e não a dimensão de tipo

`TIPO_SERVICO` tem 12 linhas e não encontra chave em `SSO_ASSUNTO` nem no código 156. Forçar o join inventaria uma classificação.

Fontes — espelho C3SL, 21/09/2016

Tabela	Papel	Silver
`SERVICO_SOLICITADO`	pedido, regional, assunto, datas, OSO	50.017
`SERVICO`	execução ligada ao pedido	337.018
`SERVICO_EXECUTADO`	quantidade e valor do item	715.973
`SITUACAO_SOLICITACAO`	histórico de situação	334.548
`GTMBAIBAIRRO` / `TIPO_SERVICO`	dimensões opcionais	75 / 12

```
SOLICITACAO 1 ──< SERVICO 1 ──< ITEM
```

Qualidade na origem

Problema	Decisão
Delimitador `;`, texto com `;` solto	descarta a linha se a contagem de campos não fecha
Latin-1 / cp1252	decode na Silver; a Bronze guarda o byte original
Linha 2 com máscara de tipo	ignorada
Byte nulo no meio do texto	removido na Silver; vira nulo
Mesma regional em duas caixas	maiúsculas só na Gold

Efeito prático: 3 linhas descartadas no CSV. O estrago não está no parser.

Medalhão, no mesmo contrato do GCP

Raw · Bronze

declaração da fonte e landing fiel. Sem tipo, sem regra.

Curated · Silver

modelo tipado, no grão da origem. Chave, data, nulo, dedup.

Consumo · Gold

fato e agregado. Só aqui existe a pergunta de negócio.

Na plataforma	Neste repositório
Landing da raw, sem regra	`jobs/bronze.py`
Curadoria no grão da origem	`jobs/silver.py`
Consumo analítico	`jobs/gold.py`
Ordem da carga	`pipeline all`: bronze, silver, gold
Bucket / tabela analítica	SeaweedFS `lake` / Parquet

Contrato do lake

```
lake/bronze/{tabela}/snapshot_date=2016-09-21/data.csv
lake/silver/{tabela}/snapshot_date=2016-09-21/data.parquet
lake/gold/fato_solicitacao_execucao/snapshot_date=2016-09-21/
lake/gold/agregado_regional_assunto/snapshot_date=2016-09-21/
lake/gold/qualidade_integracao/snapshot_date=2016-09-21/
```

Cada prefixo leva `_manifest.json` (origem, extração, sha256 ou contagem) e `_SUCCESS`.

Reexecutar **sobrescreve a mesma chave**.

Bronze — landing fiel

- Download reproduzível das seis URLs do YAML
- Gravação do conteúdo original em `data.csv`
- Metadado: URL, arquivo, `snapshot_date`, `extracted_at_utc`, bytes, sha256
- Nenhuma coluna é interpretada nesta etapa

A Silver pode ser reprocessada sem baixar de novo. A Bronze é a fonte interna.

Silver — curated no grão da fonte

- Latin-1, máscara fora, linha desbalanceada fora
- Vazio vira nulo; data inválida vira nulo; decimal com vírgula vira ponto
- Chave natural deduplicada: `SSO_IDF`, `SER_IDF`, `SEE_IDF`
- Texto original da regional **permanece** aqui

Tabela	Saiu	Descarte de parse
Solicitação	50.017	2
Serviço	337.018	1
Item executado	715.973	0
Situação	334.548	0

Gold — regras que mudam o número

Regra	Escolha
Grão	1 solicitação; agregado = regional × assunto
Tempo	horas até a **primeira** execução; senão, data de realização
Tempo negativo	sai da média e da mediana; fica o flag
Valor do item	total informado; senão quantidade × unitário
Só unitário, sem quantidade	valor nulo. A quantidade ausente permanece ausente
Rótulo	caixa alta na Gold, para unir a mesma regional
Órfão	não entra no fato; entra em `qualidade_integracao`

Resultado — volume

50.017 solicitações · 10 regionais · 195 combinações regional × assunto

Regional	Pedidos	Sem execução	Mediana
Boa Vista	10.655	88%	43 dias
Matriz	5.625	39%	9 dias
Cajuru	5.176	52%	10 dias
Santa Felicidade	5.004	44%	14 dias
Portão	4.242	43%	8 dias
Bairro Novo	3.242	30%	7 dias

Assunto com mais pedidos: **pavimentação alternativa / antipó, 11.374**.

Resultado — tempo e valor não são o mesmo conjunto

Tempo válido

9.088

de 50.017 pedidos

mediana geral: 12 dias

Mais lento, com amostra

59 dias

Boa Vista · drenagem

193 durações válidas

Maior valor

R$ 7,8 mi

manutenção corretiva

só 39 tempos válidos

Valor por regional: **Bairro Novo R$ 5,0 mi**, Portão R$ 4,0 mi, Santa Felicidade R$ 2,1 mi.
Boa Vista, líder de volume, tem **R$ 60 mil**.

Limites antes de um indicador oficial

OSO

100% preenchido, só 6 códigos (6, 2, 8, 7, 3, 4). É um código de domínio.

Órfão

92% dos serviços não acham solicitação neste recorte. 2 itens sem serviço.

Quantidade

25 milhões somados misturam unidade, m² e trecho. Fica de fora do ranking entre assuntos.

Indicador oficial de tempo ou de valor precisa, antes, de recorte compatível entre serviço e solicitação e de uma regra de data assinada pelo negócio.

Reprocessamento

1. `make pipeline` de novo
2. Mesma partição, mesma chave, novo `extracted_at_utc`
3. Contagens idênticas na segunda execução: **50.017** pedidos, **195** linhas no agregado

Falha numa etapa interrompe as seguintes. O log marca a etapa que quebrou.

Testes do contrato: parser, caminho da partição, soma de vários serviços, pedido sem execução, tempo negativo fora da métrica. **5 testes, no container.**

Trade-off e o próximo passo no mesmo desenho

Agora: um container, uma partição, Parquet e manifesto. A ordem é bronze, silver, gold.
Deixei de fora: scheduler, teste bloqueante, histórico de snapshots, painel.

Evolução	Onde entra
Assertion de chave e de órfão, com limite	modelo curated, antes de publicar a Gold
Partição por data de extração	raw, sem sobrescrever o snapshot
Tabela externa na Silver, nativa na Gold	consumo
Agendar o comando `all`	orquestrador
Alerta se o cabeçalho do C3SL mudar	raw / contrato da fonte

Volume, tempo e valor não moram juntos

Volume em Boa Vista e em antipó.
Tempo válido, longo, também em Boa Vista — num subconjunto.
Valor em manutenção corretiva, Bairro Novo e Portão, quase sem tempo válido.

A Gold separa essas três leituras. A raw não tenta respondê-las.