Pipeline SIGMU

Manutenção urbana de Curitiba

Quais regiões e tipos de pedido concentram volume, tempo e valor?

Recorte de 21/09/2016 · defesa de cerca de 20 minutos

Roteiro

Bloco	Tempo
Problema e objetivo	2 min
Fontes e qualidade	3 min
Arquitetura	3 min
Modelo e transformações	4 min
Resultados reais	4 min
Testes e próximos passos	4 min

Fontes e o que a leitura encontrou

Núcleo: solicitação, situação, serviço e item executado. Bairro e tipo de serviço também entraram.

Problema	O que foi feito
`;`, Latin-1, linha de máscara	máscara ignorada; bytes originais ficam na Bronze
Campo com `;` solto	3 linhas foram para quarentena
Chave e duplicidade	nenhuma chave nula e nenhuma duplicata

`SERVICO.SSO_IDF` liga no pedido. `SERVICO_EXECUTADO.SER_IDF` liga no serviço. Situação é histórico, não domínio.

Arquitetura

```
C3SL  ->  bronze  ->  silver  ->  gold
CSV         original    Parquet     1 linha por solicitação
```

Peça	Função
SeaweedFS	bucket `lake`, compatível com S3
`src/main.py`	sobe bronze, silver e gold
`src/lago.py`	grava e lê o SeaweedFS
`sql/gold.sql`	DuckDB monta o fato e o agregado
Docker	o pipeline roda no container

A partição é `extraction_date`, o dia da carga. O período do arquivo continua `2016-09-21`.

Regras que mudam o número

- Grão: **1 solicitação**. O assunto está no pedido.
- Vários serviços: soma de quantidade e valor, primeira data de execução.
- Sem serviço ligado: a solicitação permanece, com `possui_execucao = 0`.
- Tempo negativo: sai da média e da mediana.
- Valor ausente continua nulo. Não vira zero.
- Tipo da dimensão `TIPO_SERVICO` não tem chave. O tipo usado é `SSO_ASSUNTO`.

A carga para se a Gold tiver mais linhas do que solicitações na Silver.

Resultado — volume

50.017 solicitações. A Gold tem as mesmas 50.017.

Regional	Pedidos	Sem serviço
Boa Vista	10.655	88%
Matriz	5.625	39%
Cajuru	5.176	52%
Santa Felicidade	5.004	44%
Bairro Novo	3.242	30%

Assunto com mais pedidos: **pavimentação alternativa / antipó, 11.374**.

Resultado — tempo e valor

Tempo válido

9.088 de 50.017

12.922 tempos negativos ficaram de fora

Mais lento

Boa Vista · drenagem

mediana de cerca de 59 dias

193 tempos válidos

Maior valor

R$ 7,8 mi

manutenção corretiva

só 39 tempos válidos

Valor por regional: Bairro Novo R$ 5,0 mi, Portão R$ 4,0 mi. Boa Vista, líder de volume, tem R$ 60 mil.

310 mil serviços (92%) apontam para um pedido que não está neste arquivo. Ficam de fora do fato e entram na validação.

Testes, reexecução e o que ficou de fora

O pipeline foi executado de ponta a ponta. A mesma `extraction_date` é sobrescrita, então a segunda rodada não duplica.

Os testes verificam a quarentena, a soma de vários serviços e o tempo negativo.

Antes de um indicador oficial:

- investigar o desencontro entre serviço e solicitação;
- não usar `OSO_IDF` como número de ordem: só há seis códigos e nenhum nulo;
- não somar quantidade entre assuntos, porque a unidade muda.

Próximo passo: falhar a publicação se o órfão passar de um limite, e guardar mais de uma data de extração.